BACKUP AIRLINES

Informe metodológico

Componente de minería de datos: detección de sesiones de riesgo en la bitácora de actividad

Minería de Datos I — Proyecto de Aula

Docente: Ing. Cristian Camilo Cuadrado Beltrán

Gabriel Santiago Osorio Piñeres
Jhon Jairo Carmona Macea

Cartagena de Indias, octubre de 2026

1. Introducción y problema

Backup Airlines es una plataforma web de respaldo y gestión documental construida con Spring Boot 3 y Spring Security 6. Ofrece autenticación por roles, versionado automático, papelera con retención configurable, compartición por usuario o por enlace con vencimiento y un panel administrativo con bitácora de actividad. El proyecto viene de semestres anteriores (informe técnico, informe de planteamiento y Lienzo Canvas en documentos/antecedentes del repositorio).

La problematización (Anexo 2) mostró que las pymes de logística y servicios aeroportuarios de Cartagena de Indias manejan versiones cambiando el nombre de los archivos, no saben quién hizo el último cambio y, ante una auditoría, reconstruyen el historial revisando correos. La plataforma resuelve el registro: cada carga, descarga, vista previa, compartición, eliminación y restauración de versión queda en la tabla activity_logs. Pero el tercer efecto del árbol de problema sigue abierto: **los comportamientos extraños, como descargas masivas, no se detectan**, porque nadie revisa a mano miles de registros.

Pregunta de investigación: ¿es posible identificar automáticamente, a partir de la bitácora de actividad, las sesiones de uso cuyo comportamiento se aparta del habitual (descargas, borrados o comparticiones masivas, o actividad fuera de horario) para priorizar su revisión en una auditoría?

Objetivo del análisis: construir y evaluar un modelo que asigne a cada sesión un puntaje de riesgo y marque las más inusuales, comparándolo con una regla de umbrales sencilla.

2. Fuente y descripción de los datos

2.1 Origen

La bitácora de la aplicación se almacena en una base H2 en memoria que se borra al reiniciar, y la plataforma todavía no tiene usuarios reales. Siguiendo la guía del curso (situación C), en lugar de cambiar de proyecto se construyó un **dataset simulado** que respeta exactamente el esquema de la entidad ActivityLog y las seis acciones que la aplicación registra. El generador (mineria-datos/generar_dataset.py, semilla 42) modela:

- 35 usuarios ficticios en cuatro perfiles: coordinación de documentación (8), auxiliares de operaciones (16), calidad y cumplimiento (8) y administración (3).
- Jornada laboral de 7:00 a 18:00, turnos de sábado para operaciones y sesiones de consulta intensiva de calidad antes de auditorías a fin de mes, todos observados en el Anexo 2.
- Un conjunto de 60 archivos "habituales" por usuario sobre un total de 600.
- Un 3,5 % de sesiones de riesgo inyectadas en cuatro escenarios: descarga masiva, borrado masivo, compartición masiva y actividad fuera de horario. Esos escenarios usan archivos fuera del conjunto habitual y ráfagas rápidas de acciones.

La etiqueta de cada escenario se guarda en un archivo aparte (etiquetas_validacion.csv) que no participa en el entrenamiento. Para trabajar con datos reales se añadió al prototipo el endpoint GET /admin/logs/export.csv (solo administradores), que descarga la bitácora con las mismas columnas que el archivo simulado.

2.2 Estructura

Archivo	Contenido
data/raw/ activity_logs_simulados.csv	27.998 eventos · 6 columnas (id, created_at, username, rol, action, file_id) · 1 jul – 29 sep 2026
data/processed/ sesiones_backup_airlines.csv	2.948 sesiones · 5 columnas de identificación + 17 variables numéricas. Es el archivo que usa el modelo
data/processed/ sesiones_minedapp.csv	Las mismas 2.948 sesiones con solo las 17 variables numéricas. Es el archivo que se carga en MinedApp, para que la codificación One-Hot no convierta usuario y fecha en miles de columnas
data/processed/ etiquetas_validacion.csv	Escenario por sesión (2.848 normales y 100 de riesgo). Solo para evaluación

Las 17 variables describen volumen (n_eventos, archivos_distintos, duracion_min, eventos_por_min), tipo de acción (conteos de cada acción y proporciones de descargas, borrados y comparticiones), momento (hora_inicio, fuera_horario, fin_de_semana) y novedad (pct_archivos_nuevos). El diccionario completo está en data/README.md.

3. Metodología y uso de MinedApp

El conjunto de sesiones se recorrió en MinedApp con el archivo sesiones_minedapp.csv (17 variables numéricas). La aplicación permitió verificar la calidad de los datos y generó código para el preprocesamiento y el modelado. Como no entrena ni valida el modelo, cada etapa se ejecutó además en Python (pandas, scikit-learn y Matplotlib) en el notebook mineria-datos/analisis.ipynb, de donde provienen las métricas. El Anexo A presenta las capturas de la corrida.

Etapa	Configuración en MinedApp	Implementación ejecutada
1. Problema	Nombre "Detección de sesiones de riesgo - Backup Airlines"; tipo de tarea Otro; sin variable objetivo	Pregunta y unidad de análisis (sesión) definidas en la sección 1
2. Datos	2.948 × 17; nulos, atípicos IQR, estadísticas, 17 histogramas y matriz de correlación	Valores idénticos a los del notebook (sección 4)
3. Preprocesamiento	Nulos: mediana · Outliers: no hacer nada · StandardScaler · No codificar	Misma configuración, ajustada solo con entrenamiento dentro de un Pipeline
4. Modelado	Para la tarea Otro la app solo ofrece PCA; su código no ejecuta (pide una columna target y usa PCA.predict, que no existe)	PCA corregido como detector por error de reconstrucción y comparado con Isolation Forest, que se eligió como modelo principal
5. Evaluación	Métricas personalizadas: la app deja la plantilla vacía	Precisión, recall, F1, matriz de confusión y curva PR
6. Reporte	Reporte Markdown con el resumen de todas las decisiones	Este informe, el notebook y resultados/metricas.json

Diferencia con la configuración de MinedApp: la herramienta propone una división aleatoria con 20 % de prueba entrenamiento/prueba. Se cambió por una **división temporal** (julio y agosto para entrenar, septiembre para probar), porque en la práctica el modelo se ajusta con el historial y se aplica a sesiones futuras; una división aleatoria mezclaría días de ambos periodos y daría una evaluación optimista.

4. Exploración y preparación

4.1 Hallazgos de la exploración

- **Volumen:** la sesión típica tiene 8 eventos (mediana) y dura 35 minutos, pero el máximo llega a 115 eventos. Las descargas tienen media 2,6 y desviación 7,4: la distribución tiene una cola larga muy marcada.
- **Nulos:** solo pct_archivos_nuevos tiene 35 nulos, uno por usuario: es su primera sesión y no hay historial previo. No es un error de captura.
- **Atípicos (IQR):** los conteos de descargas (129 sesiones), comparticiones (130) y eliminaciones (68) presentan atípicos. Para variables casi siempre en cero (n_restore_version, fuera_horario) el método IQR marca cualquier valor distinto de cero y no es informativo.
- **Correlaciones:** n_eventos y archivos_distintos están casi duplicadas (r = 0,99), y ambas se asocian fuertemente con n_download (r = 0,88). Las comparticiones y su proporción (0,76) y las eliminaciones y su proporción (0,73) también van juntas.
- **Patrón horario y por perfil:** la actividad se concentra entre las 8:00 y las 17:00 con una caída al mediodía. Calidad y cumplimiento descarga en promedio 5,2 archivos por sesión, el doble o más que los demás perfiles, consistente con su rol de consulta.

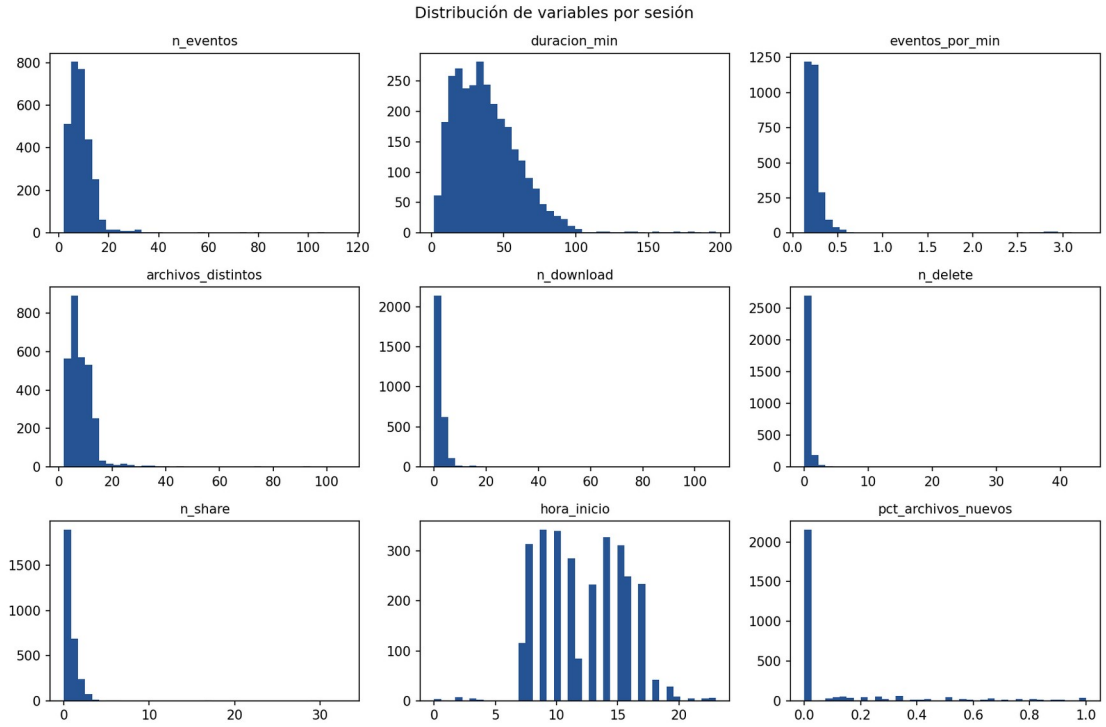


Figura 1. Distribución de las principales variables por sesión.

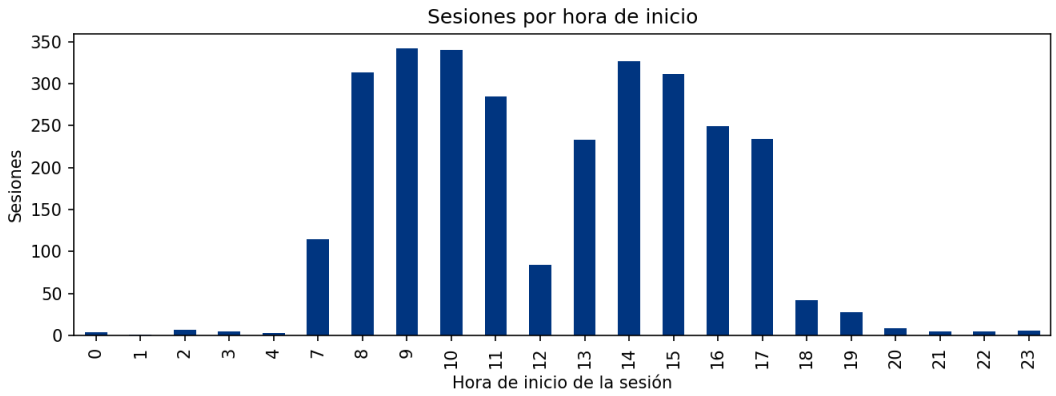


Figura 2. Número de sesiones según la hora de inicio.

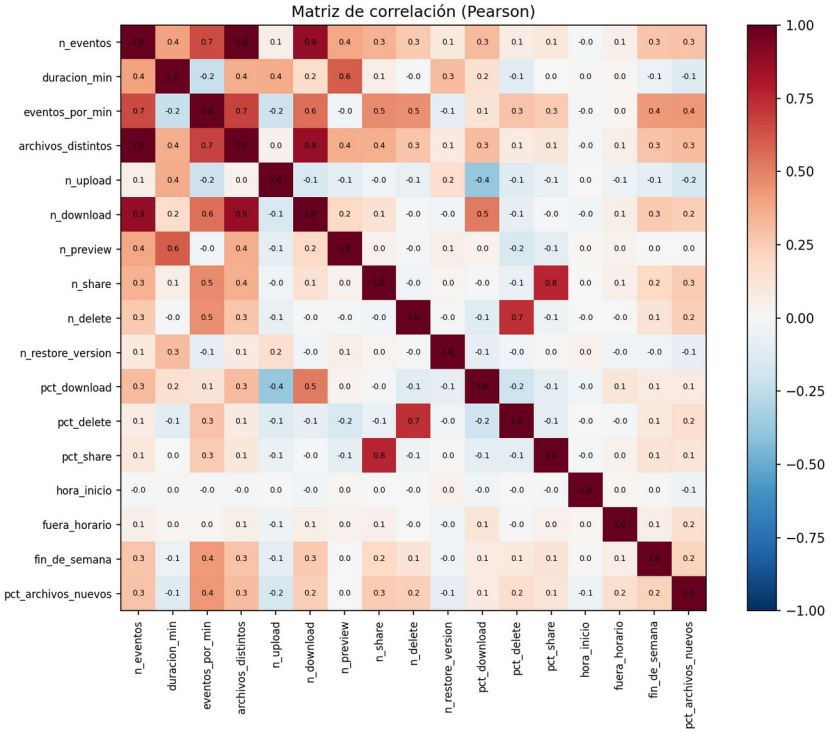


Figura 3. Matriz de correlación de Pearson entre las 17 variables.

4.2 Transformaciones y su justificación

Decisión	Aplicada	Justificación
Sesionización	Sí	Los eventos sueltos no son comparables. Se agrupan los eventos de un usuario separados por menos de 30 minutos, que es el timeout de sesión configurado en la aplicación.
Imputación de nulos	Mediana	Solo afecta a pct_archivos_nuevos. La mediana es robusta a la asimetría. Se calcula con el entrenamiento.
Tratamiento de atípicos	No	Los valores extremos son la señal que se quiere detectar. Eliminarlos o recortarlos dejaría al modelo sin lo que debe encontrar.

Decisión	Aplicada	Justificación
Escalado	Estándar	Las variables combinan proporciones (0–1) y conteos de más de 100. Se ajusta con el entrenamiento y se aplica a prueba.
Codificación categórica	No	username y rol no entran al modelo para que no aprenda identidades; todas las predictoras son numéricas.
Selección de variables	No	Se conservaron las variables correlacionadas: Isolation Forest no se ve afectado por la colinealidad como un modelo lineal.

La imputación, el escalado y el modelo forman un único Pipeline de scikit-learn, de modo que los parámetros se aprenden solo con el conjunto de entrenamiento.

5. Modelo y evaluación

5.1 Modelo

Se eligió **Isolation Forest** (Liu et al., 2008) porque no hay variable objetivo real, porque los casos de interés son pocos y distintos (justo lo que el algoritmo aísla con menos particiones) y porque entrega un puntaje continuo con el que el auditor puede ordenar las sesiones. Configuración: 300 árboles, contamination = 0,03 (proporción de sesiones que se espera revisar) y random_state = 42.

Referencia sencilla: una regla de umbrales que marca la sesión si alguna variable de conteo supera Q3 + 3·IQR del entrenamiento (por ejemplo, más de 9 descargas, 4 comparticiones o 4 eliminaciones) o si inicia fuera de horario.

Entrenamiento y prueba: 1.997 sesiones de julio y agosto para entrenar, sin etiquetas, y 951 sesiones de septiembre para probar, de las cuales 28 (2,9 %) corresponden a escenarios de riesgo.

5.2 Métricas y resultados

Como solo el 2,9 % de las sesiones de prueba son de riesgo, la exactitud global no sirve: marcar todo como normal daría 97 %. Se usaron la **precisión** (cuántas alertas eran reales: tiempo del auditor), el **recall** (cuántos incidentes se encontraron), el **F1**, la **average precision** del puntaje (área bajo la curva precisión–recall) y la **precision@k**.

Modelo	Precisión	Recall	F1	Marcadas
Isolation Forest	0,905	0,679	0,776	21
PCA por error de reconstrucción (algoritmo de MinedApp, corregido)	0,630	0,607	0,618	27
Regla IQR + horario (referencia)	0,483	1,000	0,651	58
Híbrido IF + fuera de horario (análisis posterior)	0,812	0,929	0,867	32

PCA, el único algoritmo que MinedApp ofrece para la tarea Otro, se evaluó con la misma preparación y la misma división: detecta los borrados y comparticiones masivas, pero ninguna de las 9 sesiones fuera de

horario y genera 10 falsas alarmas (average precision 0,611). Esto confirma la elección de Isolation Forest como modelo principal.

El puntaje del Isolation Forest obtuvo una average precision de 0,949 (el azar daría 0,029) y una precision@28 de 0,857: de las 28 sesiones con mayor puntaje, 24 eran de riesgo.

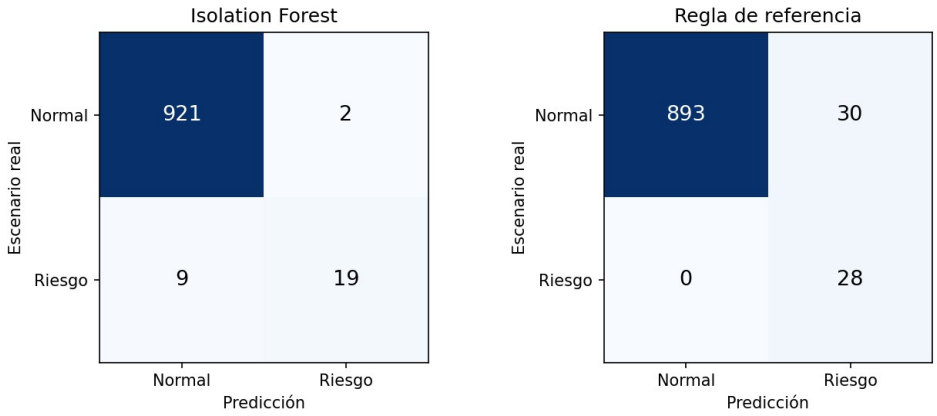


Figura 4. Matrices de confusión sobre el conjunto de prueba (septiembre).

Escenario	Sesiones	Isolation Forest	Regla	Híbrido
Descarga masiva	7	7	7	7
Borrado masivo	4	4	4	4
Compartición masiva	8	6	8	6
Fuera de horario	9	2	9	9

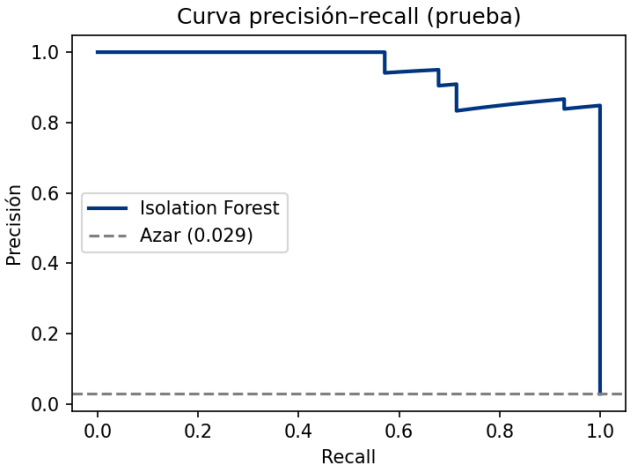


Figura 5. Curva precisión–recall del puntaje de riesgo.

El modelo híbrido no estaba planeado: se construyó después de observar que el Isolation Forest perdía la actividad nocturna. Por eso se reporta aparte y no como el resultado principal; para adoptarlo hay que validarlo con datos que no se hayan usado para diseñarlo.

6. Resultados e interpretación

1. **El modelo reduce la carga del auditor.** Frente a la regla de umbrales, marca 21 sesiones en lugar de 58 y 19 de ellas son reales. La regla encuentra todo, pero más de la mitad de sus alertas son falsas: con datos reales, ese volumen de alertas tiende a ignorarse.
2. **Detecta muy bien lo volumétrico.** Todas las descargas y borrados masivos de septiembre quedaron entre las sesiones de mayor puntaje. Es justo el escenario de los efectos E1 (pérdida de información) y E3 (accesos indebidos) del árbol de problema.
3. **Su punto débil es la actividad nocturna con pocos eventos.** Una sesión de 12 acciones a las 2:00 a.m. se parece en volumen a una normal, y la marca fuera_horario es una sola variable binaria entre 17: pesa poco en las particiones aleatorias. Tampoco detectó dos comparticiones masivas moderadas (10 y 20 enlaces).
4. **Sus falsas alarmas tienen explicación.** Las dos fueron sesiones de calidad y cumplimiento del 25 de septiembre con 16 y 20 descargas: preparación legítima de auditoría a fin de mes. Esto sugiere que el contexto (perfil, calendario de auditorías) debe entrar en una siguiente versión.
5. **Complementar es mejor que elegir.** El modelo es fuerte donde la regla es ruidosa, y la regla de horario es exacta donde el modelo falla. Integrados en el panel /admin/logs, el puntaje ordenaría la revisión y la regla horaria funcionaría como alerta directa.

7. Limitaciones y conclusiones

7.1 Qué no puede concluirse

- **Las métricas no miden el desempeño real.** Provienen de escenarios que el equipo diseñó; los incidentes reales pueden ser más sutiles. Además, la regla detecta el 100 % de la actividad fuera de horario porque los escenarios se inyectaron justamente fuera de horario: ese resultado es esperable por construcción.
- Un puntaje alto indica que una sesión es inusual, no que sea fraudulenta. La decisión siempre requiere revisión humana.
- La configuración contamination = 0,03 es un supuesto de negocio; con datos reales debe ajustarse según cuántas alertas puede atender el equipo.

7.2 Dificultades

- La aplicación no persistía la bitácora (H2 en memoria) ni permitía exportarla. Se resolvió con el endpoint de exportación, pero no hay histórico real todavía.
- La bitácora no registra IP, dispositivo ni intentos de inicio de sesión fallidos, así que no se puede medir "accesos desde lugares nuevos", un indicador planteado en el Anexo 2.

7.3 Mejoras para la siguiente versión

- Cambiar la base a modo archivo (jdbc:h2:file) o a PostgreSQL y recolectar al menos tres meses de bitácora real con el endpoint de exportación.
- Registrar IP, agente de usuario y eventos LOGIN / LOGIN_FAILED en ActivityLog.
- Agregar variables de contexto: comparación de cada sesión contra el historial del propio usuario y de su perfil, y calendario de auditorías.
- Validar el modelo híbrido con datos nuevos y, cuando existan incidentes confirmados por los auditores, evaluar un modelo supervisado.

- Mostrar el puntaje de riesgo en /admin/logs para cerrar el ciclo entre el análisis y el prototipo.

7.4 Conclusión

El procedimiento muestra que la bitácora que Backup Airlines ya registra es suficiente para construir un detector útil de sesiones de riesgo: con un Isolation Forest, 9 de cada 10 alertas fueron reales sobre los escenarios simulados, frente a menos de 5 de cada 10 con una regla fija. La validación se hizo sobre datos simulados, de modo que el siguiente paso no es técnico sino de datos: recolectar la bitácora real para confirmar o ajustar estos resultados.

8. Referencias y repositorio

Repositorio: [URL del repositorio en GitHub — completar antes de entregar]

Archivos clave: mineria-datos/analisis.ipynb (procedimiento ejecutado), mineria-datos/resultados/metricas.json (métricas), data/README.md (origen y diccionario de datos), documentos/anexos/ (Anexos 1 y 2).

Chandola, V., Banerjee, A., y Kumar, V. (2009). Anomaly detection: A survey. ACM Computing Surveys, 41(3), Artículo 15. https://doi.org/10.1145/1541880.1541882

Han, J., Kamber, M., y Pei, J. (2012). Data mining: Concepts and techniques (3.ª ed.). Morgan Kaufmann.

Liu, F. T., Ting, K. M., y Zhou, Z.-H. (2008). Isolation forest. En 2008 Eighth IEEE International Conference on Data Mining (pp. 413–422). IEEE. https://doi.org/10.1109/ICDM.2008.17

National Institute of Standards and Technology. (s.f.). Audit trail. En Computer Security Resource Center glossary. https://csrc.nist.gov/glossary/term/audit_trail

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Saito, T., y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLoS ONE, 10(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Anexo A. Evidencias de la corrida en MinedApp

Se recorrieron las etapas de MinedApp con el archivo data/processed/sesiones_minedapp.csv. A continuación se presentan las capturas de cada etapa y se transcriben los resultados. El conjunto completo de capturas y el código generado por la aplicación están en mineria-datos/minedapp/.

A.1 Etapa 1 — Problema

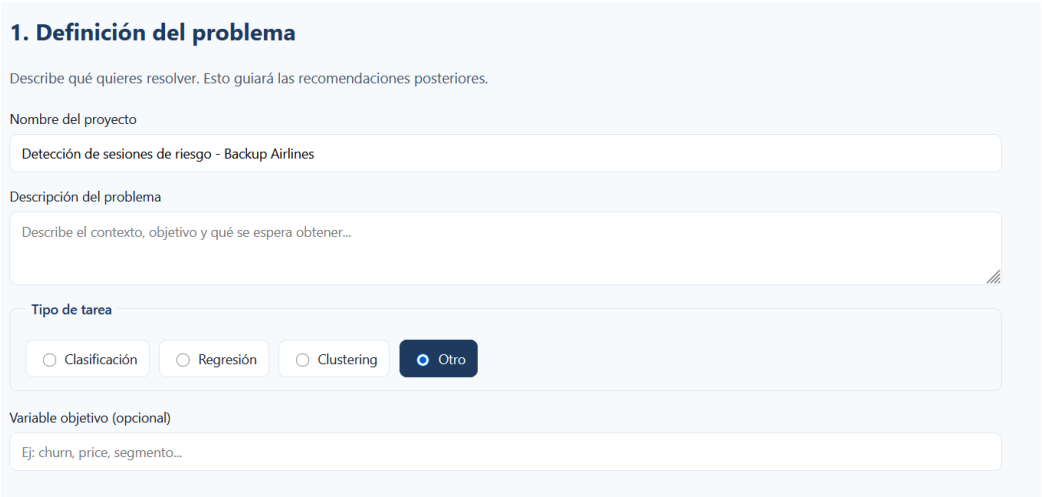


Figura A1. Definición del problema en MinedApp: tipo de tarea Otro, sin variable objetivo.

A.2 Etapa 2 — Calidad del conjunto de datos

Indicador	Resultado reportado por la aplicación
Filas × columnas	2.948 × 17
Valores nulos	35 en pct_archivos_nuevos (1,19 %); 0,00 % en las otras 16 columnas
Atípicos (IQR) más frecuentes	n_restore_version 701 · pct_archivos_nuevos 523 · eventos_por_min 220 · pct_delete 206 · n_share 130 · n_download 129 · pct_share 118 · archivos_distintos 106 · n_eventos 95
Variable sin atípicos	hora_inicio (0)

Los 35 nulos corresponden a la primera sesión de cada usuario, sin historial con el cual comparar. Los atípicos no se eliminan: un valor extremo, como 108 descargas en una sesión, es justamente el comportamiento que se quiere detectar. En variables que casi siempre valen cero (n_restore_version, fuera_horario, fin_de_semana) el método IQR tiene rango cero y marca cualquier valor distinto de cero, por lo que no es informativo.

Outliers (método IQR)

Columna	Q1	Q3	IQR	Outliers
n_eventos	5.000	11.000	6.000	95
duracion_min	20.450	51.392	30.942	33
eventos_por_min	0.190	0.263	0.073	220
archivos_distintos	5.000	10.000	5.000	106
n_upload	1.000	4.000	3.000	12
n_download	1.000	3.000	2.000	129
n_preview	1.000	4.000	3.000	49
n_share	0.000	1.000	1.000	130
n_delete	0.000	1.000	1.000	68
n_restore_version	0.000	0.000	0.000	701
pct_download	0.067	0.333	0.266	63
pct_delete	0.000	0.091	0.091	206
pct_share	0.000	0.100	0.100	118
hora_inicio	9.000	15.000	6.000	0
fuera_horario	0.000	0.000	0.000	45
fin_de_semana	0.000	0.000	0.000	17
pct_archivos_nuevos	0.000	0.091	0.091	523

Figura A2. Valores atípicos por el método IQR reportados por MinedApp.

A.3 Etapa 2 — Estadísticas descriptivas e histogramas

Estadísticas descriptivas

Métrica	n_eventos	duracion_min	eventos_por_min	archivos_distintos	n_upload	n_download	n_preview	n_share	n_delete	n_restore_version
count	2948.000	2948.000	2948.000	2948.000	2948.000	2948.000	2948.000	2948.000	2948.000	2948.000
mean	9.497	38.220	0.291	8.832	2.411	2.606	2.858	0.680	0.644	0.299
std	8.817	23.100	0.372	8.114	1.947	7.372	2.038	2.006	2.678	0.594
min	2.000	1.830	0.130	2.000	0.000	0.000	0.000	0.000	0.000	0.000
25%	5.000	20.450	0.190	5.000	1.000	1.000	1.000	0.000	0.000	0.000
50%	8.000	34.680	0.218	8.000	2.000	1.000	3.000	0.000	0.000	0.000
75%	11.000	51.392	0.263	10.000	4.000	3.000	4.000	1.000	1.000	0.000
max	115.000	196.600	3.256	107.000	10.000	108.000	16.000	33.000	44.000	4.000

Figura A3. Estadísticas descriptivas (primeras diez variables) en MinedApp.

Los valores coinciden con los calculados en el notebook (sección 4): media de 9,50 eventos por sesión con máximo de 115, y media de 2,61 descargas con máximo de 108. La app reporta la desviación estándar poblacional.

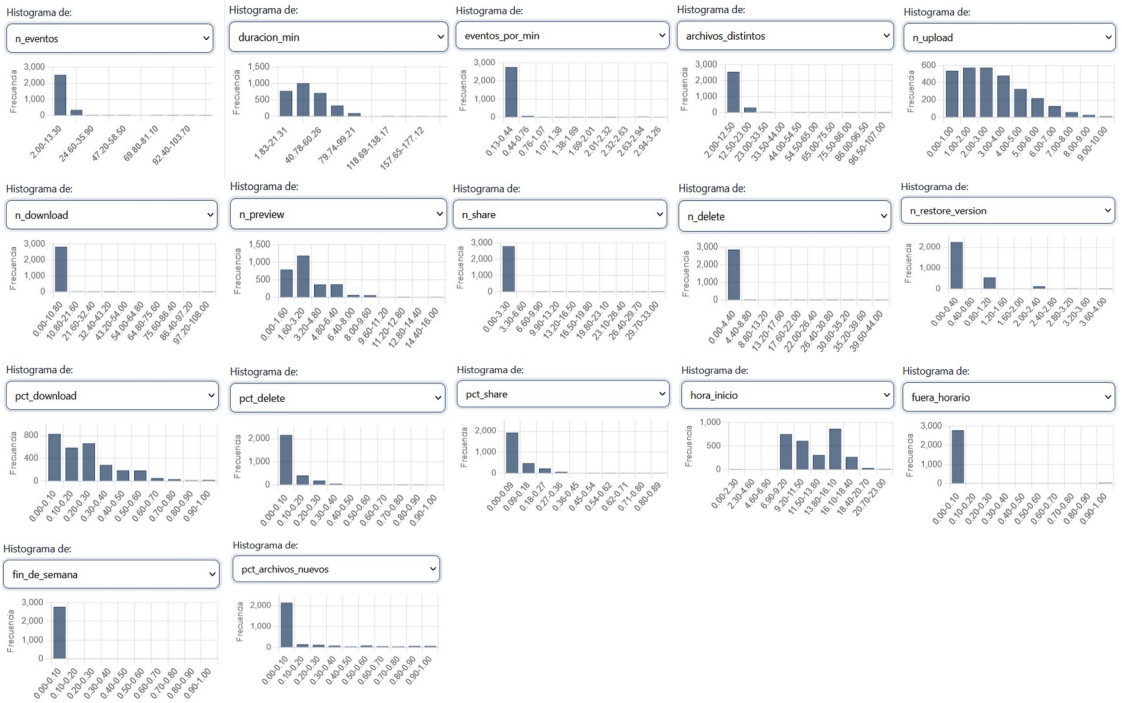


Figura A4. Los 17 histogramas generados por MinedApp.

Los histogramas confirman la forma de los datos: casi todas las variables de conteo concentran las sesiones en los valores bajos y tienen una cola larga y delgada hacia la derecha, que es donde están las sesiones de riesgo. hora_inicio muestra la jornada laboral, con la caída del mediodía.

A.4 Etapa 2 — Matriz de correlación

Matriz de correlación (numéricas)

	n_eventos	duracion_min	eventos_por_min	archivos_distintos	n_upload	n_download	n_preview	n_share	n_delete	n_restore_version	pct_download	pct_delete	pct_share
n_eventos	1.00	0.40	0.65	0.99	0.06	0.88	0.39	0.35	0.26	0.10	0.32	0.07	0.10
duracion_min	0.40	1.00	-0.22	0.36	0.38	0.18	0.60	0.06	-0.01	0.31	0.15	-0.10	0.00
eventos_por_min	0.65	-0.22	1.00	0.68	-0.21	0.55	-0.02	0.48	0.46	-0.09	0.13	0.28	0.25
archivos_distintos	0.99	0.36	0.68	1.00	0.05	0.87	0.36	0.36	0.28	0.08	0.31	0.08	0.11
n_upload	0.06	0.38	-0.21	0.05	1.00	-0.15	-0.09	-0.03	-0.07	0.16	-0.38	-0.12	-0.06
n_download	0.88	0.18	0.55	0.87	-0.15	1.00	0.20	0.15	-0.02	-0.03	0.52	-0.08	-0.02
n_preview	0.39	0.60	-0.02	0.36	-0.09	0.20	1.00	0.04	-0.01	0.05	0.03	-0.15	-0.10
n_share	0.35	0.06	0.48	0.36	-0.03	0.15	0.04	1.00	-0.03	0.02	-0.01	-0.07	0.76
n_delete	0.26	-0.01	0.46	0.28	-0.07	-0.02	-0.01	-0.03	1.00	-0.01	-0.12	0.73	-0.05
n_restore_version	0.10	0.31	-0.09	0.08	0.16	-0.03	0.05	0.02	-0.01	1.00	-0.09	-0.03	0.01
pct_download	0.32	0.15	0.13	0.31	-0.38	0.52	0.03	-0.01	-0.12	-0.09	1.00	-0.20	-0.10
pct_delete	0.07	-0.10	0.28	0.08	-0.12	-0.08	-0.15	-0.07	0.73	-0.03	-0.20	1.00	-0.09
pct_share	0.10	0.00	0.25	0.11	-0.06	-0.02	-0.10	0.76	-0.05	0.01	-0.10	-0.09	1.00
hora_inicio	-0.02	0.01	-0.01	-0.02	0.01	-0.03	0.02	0.00	-0.00	0.05	-0.03	-0.00	-0.01
fuera_horario	0.05	0.02	0.02	0.06	-0.05	0.06	0.04	0.05	-0.00	-0.03	0.12	-0.01	0.04
fin_de_semana	0.28	-0.06	0.43	0.29	-0.09	0.26	0.01	0.20	0.13	-0.04	0.08	0.10	0.14
pct_archivos_nuevos	-0.04	-0.04	-0.03	-0.04	-0.02	-0.02	-0.03	-0.00	-0.03	-0.02	0.03	-0.01	0.00

Figura A5. Matriz de correlación generada por MinedApp.

Par de variables	Coef.	Lectura
n_eventos ↔ archivos_distintos	0,99	Casi cada acción toca un archivo distinto: variables redundantes

Par de variables	Coef.	Lectura
n_eventos ↔ n_download	0,88	Las sesiones más largas son, sobre todo, de descarga
n_share ↔ pct_share	0,76	El conteo y la proporción de comparticiones van juntos
n_delete ↔ pct_delete	0,73	Igual para las eliminaciones
eventos_por_min ↔ fin_de_semana	0,43	La poca actividad de domingo es de alta intensidad: no corresponde al uso habitual
hora_inicio ↔ fuera_horario	0,02	Casi nula, porque la actividad fuera de horario está en los dos extremos del día (madrugada y noche)

El último par es relevante para el modelo: una relación lineal no captura la actividad fuera de horario, lo que anticipa la dificultad de los algoritmos para detectar ese escenario (sección 6).

A.5 Etapa 3 — Preprocesamiento

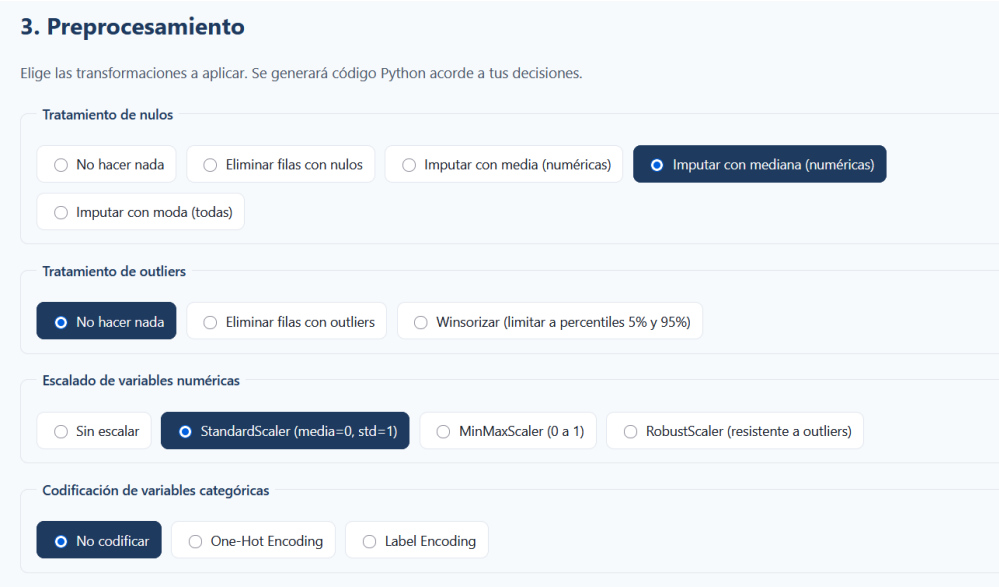


Figura A6. Configuración de preprocesamiento seleccionada en MinedApp.

Configuración: imputar nulos con la mediana, no tratar outliers, StandardScaler y no codificar (no hay variables categóricas). El código generado (mineria-datos/minedapp/codigo_minedapp_etapa3_preprocesamiento.py) se ejecutó sin errores y conserva las 2.948 filas y 17 columnas. Tiene una limitación metodológica: calcula la mediana y el escalado sobre todo el conjunto antes de dividirlo. En el notebook se corrigió ajustándolos solo con el entrenamiento.

A.6 Etapa 4 — Modelado

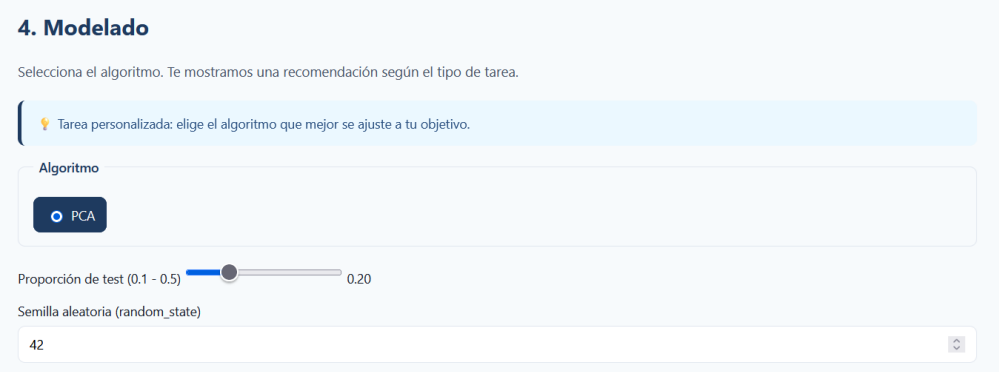


Figura A7. Etapa de modelado: para la tarea Otro la aplicación solo ofrece PCA.

Para la tarea Otro, MinedApp ofrece un único algoritmo, PCA, con 20 % de prueba y semilla 42. El código generado no se ejecuta sobre este proyecto por dos razones: busca una columna target que el dataset no tiene, porque la tarea es no supervisada, y llama a PCA.predict(), un método que no existe, porque PCA reduce dimensiones y no clasifica.

En lugar de descartarlo, PCA se corrigió para usarlo como lo permite la técnica: un detector de anomalías por error de reconstrucción (mineria-datos/minedapp/pca_corregido.py). Se ajusta con las sesiones de entrenamiento, conserva 10 componentes (92,6 % de la varianza) y marca las sesiones cuyo error supera el percentil 97 del entrenamiento. Su resultado (F1 = 0,618) se compara con el Isolation Forest en la sección 5.2.

A.7 Etapa 5 — Evaluación

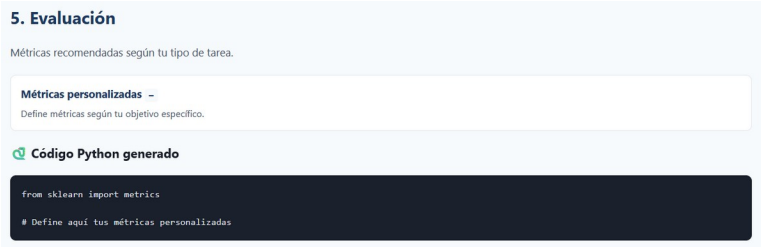


Figura A8. Etapa de evaluación: plantilla de métricas personalizadas.

Para la tarea Otro la aplicación no recomienda métricas: genera una plantilla vacía para definirlas. Las métricas se eligieron según el problema (sección 5.2): precisión, recall, F1 y average precision, adecuadas para una clase de riesgo que es solo el 2,9 % de las sesiones.

A.8 Etapa 6 — Reporte final



Figura A9. Reporte final generado por MinedApp (secciones 1 y 2).

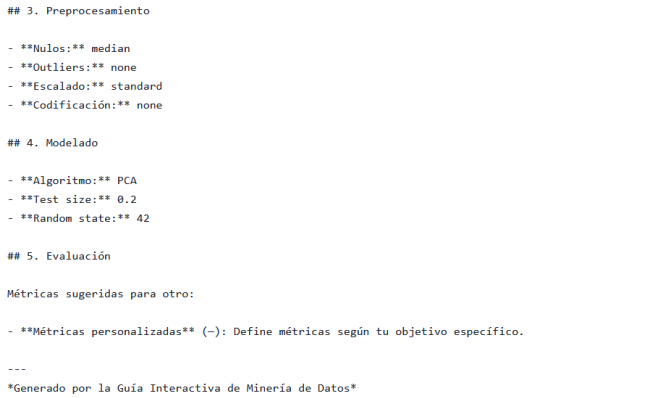


Figura A10. Reporte final generado por MinedApp (secciones 3 a 5).

El reporte resume las decisiones de la corrida: proyecto "Detección de sesiones de riesgo - Backup Airlines", tarea otro sin variable objetivo; archivo sesiones_minedapp.csv con 2.948 filas, 17 columnas numéricas y ninguna categórica; nulos por mediana, sin tratamiento de outliers, escalado estándar y sin codificación; PCA con 20 % de prueba y semilla 42; y métricas personalizadas. La transcripción textual está en mineria-datos/minedapp/reporte_minedapp.md.

El reporte registra lo que se configuró, no lo que se obtuvo: no incluye resultados del modelo ni métricas, y la descripción del problema figura como "sin descripción" porque ese campo de la etapa 1 quedó vacío. La descripción completa del problema y los resultados verificados están en las secciones 1 y 5 de este informe.

A.9 Conclusión del anexo

La corrida confirma que el dataset es apto para el análisis: 35 nulos con explicación, atípicos que son la señal buscada y valores idénticos a los del procedimiento en Python. También muestra el límite de la herramienta: para un problema de detección de anomalías solo ofrece PCA, genera un código de modelado que no ejecuta y no propone métricas. Corregir ese código y compararlo con el Isolation Forest fue una decisión del equipo, no de la aplicación.