BACKUP AIRLINES

Formato de propuesta del modelo predictivo

Detección de sesiones de riesgo en la bitácora de actividad

Minería de Datos I — Proyecto de Aula

Docente: Ing. Cristian Camilo Cuadrado Beltrán

Gabriel Santiago Osorio Piñeres
Jhon Jairo Carmona Macea

Cartagena de Indias, octubre de 2026

Estado de la propuesta: el modelo ya fue construido y evaluado sobre un dataset simulado que respeta el esquema real de la bitácora de la aplicación. Los valores reportados en la sección E provienen de esa ejecución (notebook mineria-datos/analisis.ipynb) y validan el procedimiento; no son una medida del desempeño con usuarios reales. El detalle está en el informe metodológico.

A. Identificación

Nombre del proyecto	Backup Airlines — Plataforma web de respaldo y gestión documental con detección de sesiones de riesgo
Integrantes	– Gabriel Santiago Osorio Piñeres – Jhon Jairo Carmona Macea
Repositorio	[URL del repositorio en GitHub — completar antes de entregar]
Fecha	13 de octubre de 2026

B. Problema

¿Qué situación aborda el proyecto?	Las pymes de logística y servicios aeroportuarios de Cartagena de Indias guardan y comparten documentos sujetos a auditoría (manuales, certificados, órdenes de trabajo) en nubes de uso general, sin versionado controlado, sin registro centralizado de quién hace qué y sin revisión de patrones de acceso (Anexo 2). Backup Airlines ya resuelve el control y el registro: toda acción queda en una bitácora. El problema que queda abierto es que nadie puede revisar a mano miles de registros para encontrar los comportamientos de riesgo.
¿Qué pregunta se busca responder?	¿Es posible identificar automáticamente, a partir de la bitácora de actividad, las sesiones de uso cuyo comportamiento se aparta del habitual (descargas, borrados o comparticiones masivas, o actividad fuera de horario) para priorizar su revisión en una auditoría?
¿Por qué estudiarla con datos?	Porque los efectos del árbol de problema (pérdida de información, falta de evidencia y accesos indebidos no detectados) dejan huella en la bitácora. Un modelo que puntúe cada sesión por su nivel de riesgo convierte un registro pasivo en una herramienta de control: el auditor revisa primero las pocas sesiones más inusuales en lugar de todo el historial.

C. Datos

Fuente y enlace	– Bitácora simulada con el esquema de la tabla activity_logs de la aplicación, generada por el equipo (mineria-datos/generar_dataset.py, semilla 42) a partir de los perfiles de uso del Anexo 2. Archivos: data/raw/activity_logs_simulados.csv y data/processed/sesiones_backup_airlines.csv en el repositorio. – Se simuló porque la base de la aplicación es H2 en memoria y aún no hay uso real. Para datos reales se añadió el endpoint GET /admin/logs/export.csv con las mismas columnas.
Registros y variables	27.998 eventos (6 columnas) de 35 usuarios entre el 1 de julio y el 29 de septiembre de 2026, agregados en 2.948 sesiones con 17 variables predictoras numéricas.
Variables relevantes	Volumen (n_eventos, archivos_distintos, eventos_por_min, duracion_min), tipo de acción (n_download, n_delete, n_share, n_upload, n_preview, n_restore_version y sus proporciones), momento (hora_inicio, fuera_horario, fin_de_semana) y novedad (pct_archivos_nuevos: proporción de archivos que el usuario no había tocado antes).
Variable objetivo	No aplica para entrenar. No existen incidentes reales etiquetados, por lo que no se inventan etiquetas. Las sesiones de riesgo inyectadas en la simulación se guardan aparte (etiquetas_validacion.csv) y se usan solo para evaluar.
Problemas de calidad	– 35 nulos en pct_archivos_nuevos: primera sesión de cada usuario, sin historial previo (nulo estructural). – Distribuciones muy asimétricas en los conteos y atípicos IQR que, en este problema, son precisamente la señal buscada. – Alta correlación entre n_eventos y archivos_distintos (r = 0,99). – La bitácora real no registra IP ni inicios de sesión, así que no se pueden medir accesos desde lugares nuevos.

D. Modelo propuesto

Tipo de tarea	Otro: detección de anomalías no supervisada.
Algoritmo o técnica	Isolation Forest (scikit-learn): 300 árboles, contamination = 0,03, random_state = 42.
Justificación	– No hay variable objetivo, así que se descartan clasificación y regresión. – Isolation Forest aísla observaciones con particiones aleatorias: lo raro se aísla con pocos cortes. Encaja con un problema donde los casos de interés son pocos y diferentes. – Produce un puntaje continuo que permite ordenar las sesiones para el auditor, no solo una etiqueta sí/no. – Escala bien a bitácoras grandes y no exige que los datos sigan una distribución particular.
Variables predictoras	Las 17 variables numéricas del dataset de sesiones. Se excluyen username y rol para que el modelo no aprenda identidades.

Estrategia de preparación	– Sesionización: eventos del mismo usuario separados por menos de 30 minutos (timeout de sesión de la aplicación). – Imputación por mediana de pct_archivos_nuevos. – Sin eliminación de atípicos: son la señal buscada. – Escalado estándar. Imputación y escalado se ajustan solo con entrenamiento dentro de un Pipeline.
División de los datos	Temporal: julio–agosto para entrenamiento (1.997 sesiones) y septiembre para prueba (951 sesiones). Simula el uso real: el modelo aprende del pasado y se evalúa sobre sesiones que nunca vio.

E. Evaluación

Métricas	– Precisión, recall y F1 de la clase "sesión de riesgo", con matriz de confusión. – Average precision (área bajo la curva precisión–recall) del puntaje de riesgo. – Precision@k: precisión de las k sesiones con mayor puntaje (k = sesiones de riesgo en prueba).
Razón de la elección	Solo cerca del 3 % de las sesiones son de riesgo, así que la exactitud global engaña: marcar todo como normal daría 97 %. La precisión mide cuánto tiempo del auditor se desperdicia en falsas alarmas; el recall, cuántos incidentes se escapan. La curva PR es la recomendada para clases desbalanceadas (Saito y Rehmsmeier, 2015).
Modelo de referencia	Regla de umbrales: marcar la sesión si alguna variable de conteo supera Q3 + 3·IQR del entrenamiento o si inicia fuera de horario. Representa lo que haría un administrador con reglas fijas.

Resultados obtenidos al ejecutar el procedimiento (septiembre, 951 sesiones, 28 de riesgo):

Modelo	Precisión	Recall	F1	Marcadas
Isolation Forest	0,905	0,679	0,776	21
PCA por error de reconstrucción (algoritmo de MinedApp, corregido)	0,630	0,607	0,618	27
Regla IQR + horario (referencia)	0,483	1,000	0,651	58
Híbrido IF + fuera de horario (análisis posterior)	0,812	0,929	0,867	32

Average precision del Isolation Forest: 0,949. Precision@28: 0,857.

F. Resultado esperado

¿Qué se espera obtener?	Un puntaje de riesgo por sesión, integrable en el panel /admin/logs, que ordene la actividad de la más a la menos inusual y marque automáticamente un número reducido de sesiones para revisión.

Decisión que apoya	– Qué sesiones revisar primero ante una auditoría o un incidente. – Cuándo suspender temporalmente un usuario o revocar enlaces públicos tras una compartición masiva. – Qué umbrales y políticas de retención ajustar en la plataforma.
Principales limitaciones	– Los datos son simulados: las métricas validan el procedimiento, no el desempeño real. – El modelo pierde la actividad fuera de horario con pocos eventos (2 de 9 detectadas); la combinación con la regla de horario se identificó después de ver los resultados y debe validarse con datos nuevos. – Marca como riesgo algunas sesiones legítimas de preparación de auditoría a fin de mes. – La bitácora no registra IP, dispositivo ni intentos de acceso fallidos. – Un puntaje alto indica algo inusual, no un fraude: siempre requiere revisión humana.

Referencias: Liu, F. T., Ting, K. M., y Zhou, Z.-H. (2008). Isolation forest. En 2008 Eighth IEEE International Conference on Data Mining (pp. 413–422). https://doi.org/10.1109/ICDM.2008.17 · Saito, T., y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLoS ONE, 10(3), e0118432. https://doi.org/10.1371/journal.pone.0118432